
Introdução ao Processamento Digital de Imagens

Grupo:

Emmanuella Faustino Albuquerque - 20170002239

Lucas Jurani Lustosa Lopes - 2016022684

Gean Rocha da Silva Junior - 20180163565

Projeto Final: Classificação da idade de Radiografias Panorâmicas Odontológicas

22 de junho de 2022

VISÃO GERAL

A super-resolução tenta construir uma imagem de alta resolução dada uma imagem de baixa resolução. O objetivo deste trabalho é verificar se a super-resolução cria informações úteis ou não para a classificação, no contexto das Radiografias Panorâmicas Odontológicas.

Dessa forma, neste trabalho, utilizamos o algoritmo de super-resolução e os de geração de novos dados (data augmentation) como a geração de Zoom, de Rotação e do Crop Aleatório, com o intuito de fazer essa comparação.

ATIVIDADES DESENVOLVIDAS

Nesta seção, serão apresentadas as atividades desenvolvidas, isto é, a descrição das funcionalidade e os resultados obtidos.

1. Super-resolução de uma imagem (Super-Resolution)

Fundamentação Teórica

A super-resolução, é uma técnica da área de processamento digital de imagens, que busca proporcionar maior resolução a partir de imagens de baixa resolução. Através de técnicas de Aprendizagem de Máquina é possível, com super-resolução, restaurar imagens de baixa qualidade aumentando a sua resolução.

Estratégia

Antes da aplicação de algum método de super-resolução em cima dos dados, foram feitos tratamentos nos dados, em que a resolução das imagens foram diminuídas mantendo o seu aspect ratio, após isso, aumentamos o tamanho das imagens para que percam ainda mais dados que as compõem. Esse processo foi feito para que o método de super-resolução utilizado fosse colocado a prova, visto que o seu objetivo é aumentar a resolução de uma imagem.

Após isso, foi utilizada uma API fornecida pela 'DeepAi.org' que processa imagens utilizando um método de super-resolução chamado 'SRGAN'.

Resultados

> Imagem Original



> Diminuição da Resolução da Imagem mantendo o aspect ratio

Diminuindo o tamanho da imagem, mantendo o aspect ratio, e posteriormente aumentando, também mantendo o aspect ratio, foi possível obter uma imagem com baixa resolução.



> Aplicação do método de super-resolução (SRGAN)

Modelos pré-treinados com esse tipo de imagem (arcada dentária) não foram encontrados. E por esse fato o método de super-resolução utilizado não foi eficaz em adicionar resolução à imagem.

Para que o método seja eficiente, é necessário que mais dados como esses sejam gerados e inseridos em redes que façam essa tarefa.



2. Data augmentation

Fundamentação Teórica

Nem sempre temos disponível uma grande quantidade de imagens para utilizarmos em projetos de inteligência artificial. Para lidarmos com esse problema, podemos utilizar técnicas como a de Data Augmentation.

Data Augmentation é uma técnica utilizada em pré-processamento de dados, para aumentar e diversificar a quantidade de dados presentes em um Dataset (i.e um conjunto de dados, no nosso caso imagens).



Dessa forma, com o intuito de aumentar o tamanho do dataset criando novas imagens a partir da base de dados existente, foi realizado o tratamento das imagens de entrada, utilizando algumas técnicas como rotação, zoom e crop aleatório.

Estratégia e Resultados


➤ Rotação (± 10 graus)

A ideia é gerar uma leve rotação na radiografia dentária de $+ 10$ graus e $- 10$ graus da área de interesse. Considerando isso, percebeu-se que ao realizar a rotação da imagem somente da área de interesse, regiões pretas eram criadas. Dessa forma, com o propósito de evitar que situações como essa ocorressem, foi realizada a rotação na imagem inteira e somente depois realizado o crop da região de interesse.

($- 10$) graus




($+ 10$) graus




➤ Zoom (± 10 %)

No caso do Zoom, o objetivo seria gerar um leve aumento ($+ 10\%$) e redução ($- 10\%$) na imagem da radiografia dentária. A situação das regiões/bordas também ocorre com o Zoom, no caso do Zoom Out aparecem bordas brancas/tons de cinza em volta da imagem, logo, foi realizada a Redução e a Ampliação da imagem e só após o crop da região de interesse.

Zoom Out - Redução



Zoom in - Ampliação





➤ Recorte Aleatório (Random Crop)

O recorte aleatório é uma técnica de aumento de dados em que criamos um subconjunto aleatório de uma imagem original. Isso ajuda nosso modelo a generalizar melhor, porque os objetos de interesse que queremos que nossos modelos aprendam nem sempre são totalmente visíveis na imagem ou na mesma escala em nossos dados de treinamento. A imagem cortada de saída precisa ser um subconjunto totalmente da imagem original. Se escolhermos aleatoriamente as coordenadas na imagem de entrada sem tomar o devido cuidado podemos nos deparar com dados inúteis, então o recomendado é aplicar o método somente na região de interesse.

De maneira mais geral, a maioria dos exemplos de modelos de visão computacional de aplicativos móveis, pode se beneficiar do aumento de dados advindo do corte aleatório. Um usuário pode segurar seu telefone a distâncias variadas dos objetos que procura reconhecer, e esses objetos nem sempre estão completamente enquadrados.

Existem muitas variações de corte aleatório que podemos realizar. Essas implementações também dependem do tipo de problema que estamos resolvendo, no presente trabalho foi escolhido arbitrariamente que o corte deveria ser em uma região com metade das dimensões da imagem original, ou seja, com metade da largura e metade do comprimento da imagem de origem, mas posteriormente ficou definido com sendo um corte de 244 x 244 pixels.



3. Classificação

Fundamentação Teórica

A classificação de imagens é uma das áreas de aplicação da Aprendizagem de Máquina, na qual dado um modelo, este tem por objetivo definir a qual classe algo pertence. Dessa forma, dado um problema de modelagem preditiva, definindo rótulos de classes, podemos utilizar a classificação para prever se determinado exemplo de entrada pertence a tal classe.

Aplicações de classificação utilizando dados médicos, como a radiografia panorâmica, possuem dados limitados, dados que são imagens privadas de clientes, por esse motivo, existem poucas aplicações relacionadas a esse tema.

Estratégia

Foram utilizados dois conjuntos de dados, o primeiro conjunto de dados as imagens utilizadas passaram por um primeiro pré-processamento responsável por recortar a imagem pegando somente a região de interesse da imagem. Após isso foi aplicado métodos de data augmentation.

Para o segundo conjunto de dados, o mesmo pré-processamento e métodos de data augmentation foram feitos, sendo que foi aplicado o método de super-resolução a esse conjunto de dados.

Além disso, o objetivo do classificador é dizer se determinado dado pertence ao grupo de dados em que as amostras foram geradas a partir de indivíduos com 22 anos de idade ou mais, ou de indivíduos abaixo dos 22 anos de idade.

Para a classificação, foram utilizadas 3 arquiteturas de modelo. A primeira VGG-16, é uma rede neural convolucional (CNN), que consiste em uma entrada de dados de dimensão 224x224, camadas de convolução 3x3, o mesmo padding e camada de maxpool 2x2. Além disso possui o número 16 em seu nome que representa o número de camadas que possuem pesos.

A segunda arquitetura utilizada foi a MobilenetV2, uma CNN que busca performar bem em aparelhos móveis. Além disso, foram utilizados os pesos de um modelo treinado com a arquitetura MobilenetV2 a partir de uma base de dados chamada ImageNet.

E por fim, outra técnica utilizada foi uma para reduzir o overfitting introduzindo a regularização de dropout na rede. Ao aplicar o dropout em uma camada, ele descarta aleatoriamente um número de unidades da camada de saída durante o processo de treinamento.

Resultados

➤ Resultado da Primeira Classificação sem super-resolução


```
Epoch 5/5  
179/179 [=====] - 237s 1s/step - loss: 0.6933 - accuracy: 0.4972 - val_loss: 0.6995 - val_accuac  
y: 1.0000
```

➤ Resultado da Primeira Classificação com super-resolução

```
Epoch 5/5  
179/179 [=====] - 241s 1s/step - loss: 0.6935 - accuracy: 0.4972 - val_loss: 0.6994 - val_accuac  
y: 1.0000
```


➤ Resultado do MobileNetV2 sem super-resolução

Epoch 10/10
179/179 [=====] - 16s 87ms/step - loss: 0.4566 - accuracy: 0.7640 - val_loss: 0.3209 - val_accuracy: 0.9286




➤ Resultado do MobileNetV2 com super-resolução

179/179 [=====] - 15s 86ms/step - loss: 0.5077 - accuracy: 0.7402 - val_loss: 0.7649 - val_accuracy: 0.7857



➤ Resultado do Dropout sem super-resolução


179/179 [=====] - 22s 121ms/step - loss: 0.1116 - accuracy: 0.9637 - val_loss: 3.5326 - val_accuracy: 0.4286



1/1 [=====] - 0s 88ms/step
This image most likely belongs to 22Under with a 99.99 percent confidence.

➤ Resultado do Dropout com super-resolução

179/179 [=====] - 15s 86ms/step - loss: 0.5077 - accuracy: 0.7402 - val_loss: 0.7649 - val_accuracy: 0.7857



```
1/1 [=====] - 0s 43ms/step  
This image most likely belongs to 22Under with a 77.19 percent confidence.
```

CONCLUSÃO

Por meio de métodos de data augmentation, sendo eles zoom, rotação e crop aleatório, foi possível fazer com que uma imagem do conteúdo de dados original gerasse outras 9 imagens, totalizando um total de 730 imagens para o conjunto de imagens utilizado para a classificação sem a aplicação do método de super-resolução e outras 730 imagens para o conjunto de dados que utiliza do método, totalizando 1460 imagens utilizadas.

No nosso caso de estudo, a super-resolução não surtiu o efeito esperado, já que não foi capaz de aumentar a resolução, pois o modelo utilizado não possui imagens anteriores de Radiografias Panorâmicas Odontológicas

Dessa forma, na arquitetura MobileNet com pesos da ImageNet, os dados sem super-resolução performaram melhor tanto em Loss quanto na Acurácia, tanto no treinamento quanto no teste. Já no Dropout, os dados com super-resolução performaram melhor no conjunto de testes.

REFERÊNCIAS BIBLIOGRÁFICAS

[1] Image Super-Resolution in Python. Disponível em:

<https://medium.com/gdplabs/image-super-resolution-in-python-cae6050b13d8>. Acesso em: 20 de junho de 2022.

[2] How to Configure Image Data Augmentation in Keras. Disponível em:

<https://machinelearningmastery.com/how-to-configure-image-data-augmentation-when-training-deep-learning-neural-networks/>. Acesso em: 20 de junho de 2022.

[3] Why and How to Implement Random Crop Data Augmentation. Disponível em:

<https://blog.roboflow.com/why-and-how-to-implement-random-crop-data-augmentation/>. Acesso em 20 de junho de 2022.